《大数据应用项目实践》课程设计

（2024/2025 学年第二学期）

指导教师：夏劲松、霍戌文

企业指导教师：张果

任
务
书

计算机科学与技术（人工智能）学院

2025 年 05 月

《大数据应用项目实践》
任务书

《大数据应用项目实践》是计算机科学与技术专业的专业课程之一，这是一门以大数据思维为核心，以大数据技术和工业界的大数据处理相关的实际案例为主要内容的课程。详细讲解主流的离线和实时等大数据技术，最后将各项技术融合使用完成若干真实项目案例。可以帮助学生快速系统地掌握前沿实用大数据技术原理、应用场景、使用方法。本课程从大数据处理的入门基础讲起，循序渐进，不断进阶，每一个部分均以案例驱动的方式进行，所有案例全部来自于工业界场景典型案例，让学生通过真实的案例和应用掌握大数据处理技术。

通过《大数据应用项目实践》课程学习，学生需深入理解大数据核心知识，提高运用知识解决实际问题的能力，强化大数据思维，提升实际处理能力。

一、课程目标：

本课程结束时，学生应该具备的如果方面相关的知识、技能、态度或价值观：

- 1-4 能够将**工程基础知识、专业知识和数学模型**用于计算机复杂工程问题的方案比较和综合。（*知识要求：运用工程知识，专业知识和数据模型*）
- 2-1 能识别计算机复杂工程问题，并能通过调研，明确表达计算机复杂工程问题的**需求**和**关键过程**；（*分析能力要求：识别需求和关键过程*）
- 5-1 能够了解和掌握现代工程**工具**和信息技术工具，理解其**技术优势和局限性**；（*掌握工具（包括社区）使用及了解其局限性*）
- 3-3 能够根据设计方案，充分考虑性价比，遵循软件工程规范，实现满足要求的计算机系统。（*设计，方案，性价比，软件工程规范*）

二、内容描述：

消费者价格指数（CPI）是衡量通胀水平的重要宏观经济指标，但传统CPI依赖人工调研与月度统计更新，存在时效性差、颗粒度粗、覆盖不全等固有缺陷。随着电商平台数据的大规模生成，构建高频（按日）价格指数成为可能。电商数据具备更新快、覆盖面广、精度高等优势，可突破传统CPI的限制，形成对市场更灵敏的监测手段。

本项目使用云服务实现电商价格指数的计算，实践目标如下：

- 熟练掌握对象存储的数据管理能力
- 利用ClickHouse实现高效的列式查询与价格指数构建
- 基于 Python 的自动化计算流程，实现一套自动化、高并发、可复用的价格指数计算体系
- 使用数据湖的解决方案（可选）

三、 实践要求

1. 阅读文档

了解实践项目背景。

https://zhuanlan.zhihu.com/p/21331379

https://zhuanlan.zhihu.com/p/21347457

https://zhuanlan.zhihu.com/p/21798044

https://zhuanlan.zhihu.com/p/22036353

阅读文章Online and official price indexes: Measuring Argentina’s inflation

（重点阅读3.1，了解价格指数的概念和计算方式）。

2. 数据的获取和预处理

（1）数据源：

使用阿里云天池平台公开数据集，主要包括：

category.csv：商品分类信息

product.csv：商品表

price.csv：商品每日价格与销量数据

（2）操作要求：

将数据集上传至对象存储，构建个人Bucket并配置权限

对接OOS与clickhouse

对字段类型进行适配与转换，统一时间格式、价格单位、分类编码

四、 架构设计

整合项目整体思路，包括存储，计算，可视化部分。

1. 价格指数核心算法

（1）异常处理机制（ClickHouse实现）

- 价格可能为空
- ……

（2）指数计算（支持链式）

- 设计分类价格指数：每类商品按销量加权平均价格
- 构建日价格指数时间序列，结合 GROUP BY 与 ARRAY JOIN 聚合
- 采用 阿里云 Quick BI 或 Python matplotlib等进行可视化
- 输出内容为日度指数趋势图。

四、 测试与验证

（1）单元测试

使用手工构造的小规模 CSV 上传 OSS，验证字段解析、SQL输出正确

（2）集成测试

覆盖率测试：验证商品覆盖≥80%，异常过滤准确性 95%（可选）

五、 预期成果

（1）设计文档

设计文档包括需求分析，表设计，核心python代码逻辑，核心sql代码逻辑

（2）实践报告

实践报告需要包括需求分析，表设计，SQL算法以及关键语句的分析，详细设计（有代码的放代码），结果分析（运行代码截图），实验心得与课程反馈。

（3）源程序

六、工作内容及工作计划：(17-18 周)

课次	工作内容	计划学时	备注
1	背景介绍、论文研读	2	地点：10-414；人数：36 批次：1 批；节次：12

2	设计开发者文档	8	地点：10-414；人数：36 批次：1 批；节次：34567
3	文档优化、文档重构	2	地点：10-414；人数：36 批次：1 批；节次：89
4	数据集结构分析与预处理方案制定	4	地点：10-414；人数：36 批次：1 批；节次：1234
5	对象存储与 clickhouse 的环境部署	4	地点：10-414；人数：36 批次：1 批；节次：6789
6	自动化计算流程脚本开发	8	地点：10-414；人数：36 批次：1 批；节次：123456789
7	可视化输出设计与结果展示	4	地点：10-414；人数：36 批次：1 批；节次：1234
8	编写总结报告	4	地点：10-414；人数：36 批次：1 批；节次：6789
9	答辩考核	4	地点：10-414；人数：36 批次：1 批；节次：6789
10	合计	40	

七、考核成绩评定标准：

本课程最终成绩按五级评分：优、良、中、及格、不及格。五个级别对应的百分之关系为：

A：成绩>=90；B：90>成绩>=80；C：80>成绩>=70；D：70>成绩>=60；E：60<成绩。

本课程设计的评价由五部分组成，包括课堂表现（10%），工作日志（20%），过程报告（20%），答辩测试（10%），项目成果（40%）。具体考核要求如下：

考核方式或途径	考核要求	考核权重
课堂表现	以课堂完成工作内容的数量及质量为评分依据；	10%

工作日志	按照学生提交工作日志情况打分；	20%
过程报告	根据学生提交的过程报告完成情况及质量，进行考评；	20%
答辩测试	根据内容汇报、回答问题打分；	10%
项目成果	根据实践报告功能完整性、性能指标等情况进行评分；	40%

八、推荐教材及参考资料

1、了解实践项目背景。

https://zhuanlan.zhihu.com/p/21331379

https://zhuanlan.zhihu.com/p/21347457

https://zhuanlan.zhihu.com/p/21798044

https://zhuanlan.zhihu.com/p/22036353

2、阅读文章Online and official price indexes: Measuring Argentina’s inflation（重点阅读3.1，了解价格指数的概念和计算方式）。